修士論文 最終学期 第 1 回 研究報告

評価点を弱教師とした事前学習による日本語ホテルレビューのアスペクト感情分析

— 暗示的なネガティブ表現の検出に向けて —（仮題）

2026 年 10 月 1 日
Gu Jincheng

本日の目的

ご報告

・夏学期に実験はすべて完了しました

・主な結果と、当初の仮説と異なった点

・修論完成までの計画とリスク

本日決めていただきたいこと

① 主結果にどの実験構成を置くか

② RQ3 （仮説と逆の結果）の扱い

③ データ量・年代実験の位置づけ

④ 論文の言語・体裁・中間提出日

⑤ レビュー本文の引用可否

⑥ 追加実験・対外発表の要否

→ p.14 に選択肢と私の提案をまとめています

研究の問いと手法（再確認）

- 課題： Gold データの感情ラベルの 86.5% は暗示的（感情語を含まない）。ネガティブでは約 92%
- ベースライン（ E1 ）では、暗示的ネガティブの F1 が明示的より 4.3pp 低い
- 着想：楽天トラベルのレビューには投稿者による観点別の評価点がある → 約 700 万件の「無料の弱ラベル」



データの健全性：パネルと Gold の重複 11,369 件（完全一致 9,911 ＋近似 1,458 ）を除外。 Gold の約 79% がパネル由来であることを発見し、テスト汚染を防止

夏学期の進捗：実験はすべて完了

段階	内容	状態
データ整備	全 16 年・約 700 万件を解析、列対応を公式仕様で確定、 Gold 重複を除外	完了
主実験	E7 → E8 、有意性検定（ paired bootstrap ）、複数 seed 、アブレーション 4 種	完了
分析実験	データ量（ 58 万〜 676 万件）、年代（近年 / 早年）	完了
追加実験	日本語専用モデル比較、積み上げ、対照学習（ SCL ）との比較	完了
未実施	RQ4 （評価点と本文の一致度）、事例分析	執筆前に実施（約 1 週間）

残りは主に執筆。 GPU を要する実験は原則として不要

A1 E1 vs E8（XLM-R）

主結果：弱教師事前学習はネガティブ検出を改善する

指標	E1	E8	差 Δ	95% CI	判定
ネガティブ集約 F1	0.7023	0.7223	+2.00pp	[+0.80, +3.21]	有意
マイクロ F1	0.8234	0.8303	+0.70pp	[+0.20, +1.23]	有意
ポジティブ集約 F1	0.8608	0.8637	+0.30pp	[−0.25, +0.83]	非有意

頑健性

E1 全 7 回： 0.7075 ± 0.0048

E8 3 seed： 0.7235 ± 0.0052

→ 差 +1.60pp。 E8 の最低値が E1 の最高値を上回る

解釈

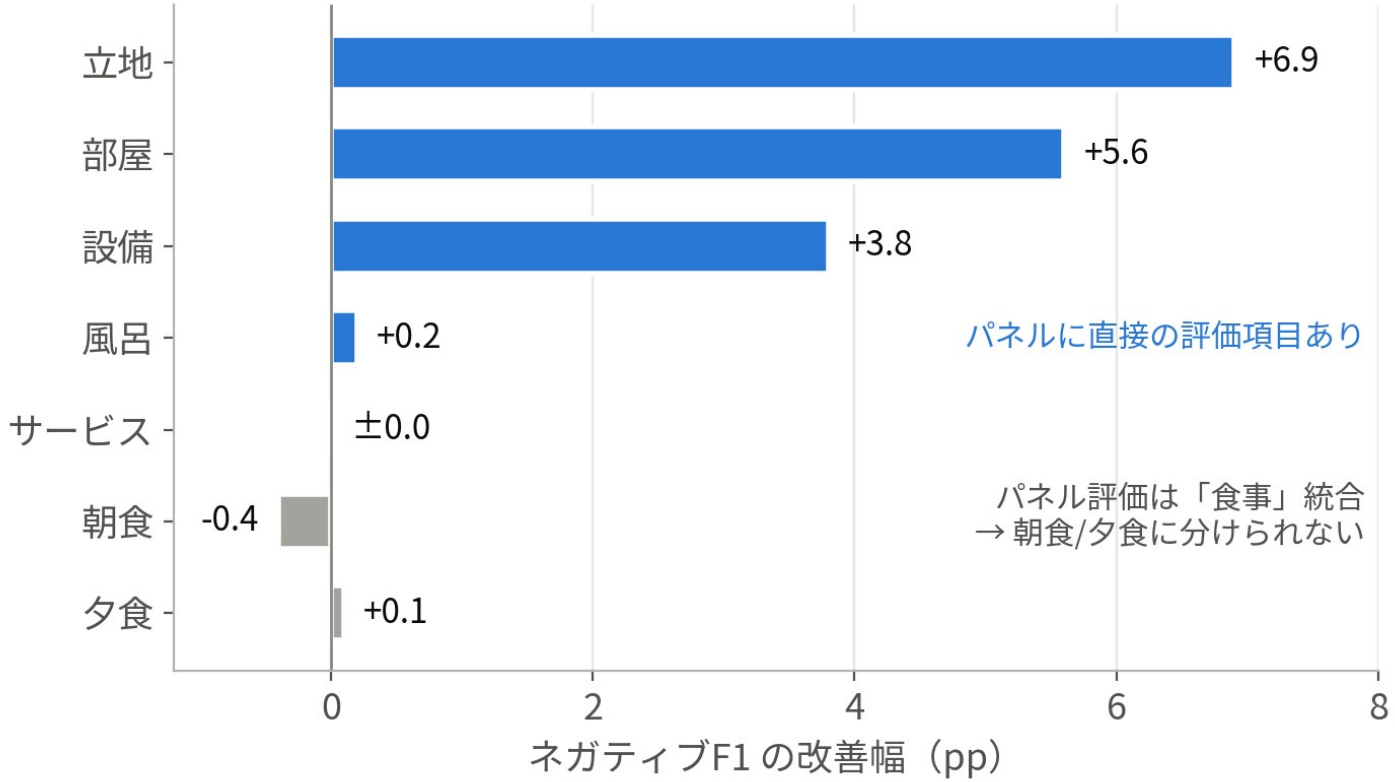
ネガのみ有意、ポジは非有意

→ 全体の底上げではなく、ネガティブに特異的に効いている

注：同一 seed でも GPU の非決定性で最大約 0.7pp 揺れるため、単一 run ではなく分布で比較

観点別ネガティブ F1 （E1 → E8）

どこに効いたか：評価項目がある観点に集中



・改善は、パネルの評価項目が直接対応する観点（立地・部屋・設備）に集中

・朝食・夕食はほぼ改善なし：パネルは「食事」 1 項目のみ → 粒度のミスマッチ

・立地は事前学習では最も弱いヘッド（F1 0.35 ）だったが、下流では最大の改善

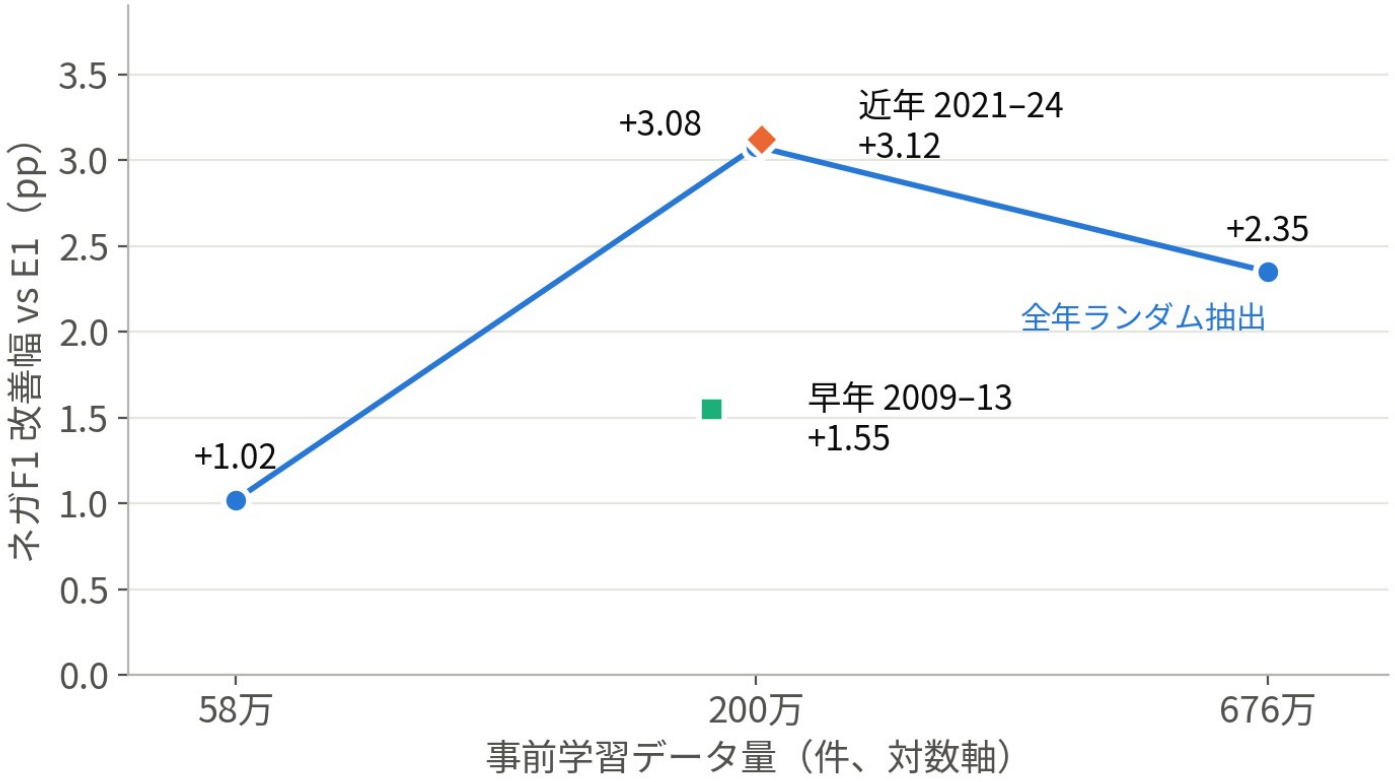
→ 事前学習タスクの精度 ≠ 下流での価値

アブレーション：主構成の各選択は妥当

比較	条件	ネガ F1	マイクロ F1	結論
A2 微調整方法	全パラメータ（主構成）	0.7224	0.8303	最良
	層別学習率	0.7031	0.8178	E1 （ 0.7033 ）と同等 → 利点が消える
	エンコーダ凍結	0.6040	0.6277	下限
A3 事前学習 epoch	1 epoch	0.7194	0.8317	2 epoch とほぼ同じ → 1 epoch で十分
A4 総合評価ヘッド	7 ヘッド（総合を追加）	0.7215	0.8300	効果なし → 6 ヘッドで正しい

・発見：層別学習率では弱教師の利点が消える → 事前学習の表現は「エンコーダを十分に更新できて初めて活きる」

データ量と年代の影響（分析的実験）



・量： 200 万件で最大、 676 万件ではかえって低下

・年代：同規模でも 近年 +3.12pp vs 早年 +1.55pp

– テスト（ 2018–19 年）に文体が近いデータほど有効

– 評価点ラベルの分布は年代間で大差なし → ラベルではなく言語ドメインの差

注意（ご相談③）

各点は単一 run かつテストで比較 → 最適構成の「選択」には使わず、分析として報告したい

ベースモデル比較と積み上げ

構成	ネガ集約 F1	E1 比
XLM-R E1 （5 seed）	0.7066	—
DeBERTa-ja E1 （5 seed）	0.7255	+1.9pp
DeBERTa-ja + E7/E8 （3 seed）	0.7447	+3.8pp

注：数値は保存した予測からの再計算（bootstrap と同じ定義）。E7/E8 は近年 200 万件で事前学習。XLM-R ＋ E7/E8 の結果は p.5

・日本語専用モデル（DeBERTa-ja）は暗示ネガ F1 を有意に改善（+0.98pp, P=0.99）

– 手がかりの少ない文（短文・否定形なし）で差が大きい

・DeBERTa 上でも E7/E8 が +1.85pp（有意）→ 2 つの改善は相補的

・否定的結果：対照学習（SCL, SCAPT 核心）は BCE より −1.87pp（有意に劣る）

– 文書単位の 1 ビット vs 観点別の 6 ビット

研究課題（RQ）ごとの回答

RQ	問い	回答
RQ1	暗示的な観点感情は明示的より難しいか	Yes （− 4.3pp ）。ただし差の指標自体は seed 間で揺れが大きい
RQ2	評価点による弱教師事前学習は ABSA を改善するか	Yes （ +1.60pp 、有意・頑健）
RQ3	改善は暗示的ネガティブで特に大きいか	No （当初仮説と逆）。暗示ネガを有意に改善したのは日本語専用モデル → ご相談②
RQ4	評価点と本文はどの程度一致するか（弱ラベルのノイズ）	未分析 → 執筆前に実施
RQ5	oseti による明示 / 暗示の分割は信頼できるか	人手検証は実施せず、限界として記載（決定済み）
RQ6	LLM は暗示的な表現で優れるか	実施せず（範囲外）

論文の構成案

章	内容	素材の状況
1　序論	動機、 RQ	あり
2　関連研究	ABSA 、弱教師、ドメイン適応事前学習など 27 本	整理済み → 論文調に書き直し
3　データ	Gold 、パネル、重複除外、列対応の確定	あり（図は未作成）
4　手法	2 段階学習（ E7 → E8 ）	あり
5　実験	主結果、アブレーション	あり（図表は未作成）
6　分析	観点別、データ量・年代、ベースモデル、機構分析、 RQ4 、事例	RQ4 ・事例が未実施
7　結論	RQ への回答、限界、今後の課題	限界のリストは確定

リスクと対応

リスク	対応
テストセットで構成を比較した（データ量・年代）	分析的実験として位置づけ、主表は事前に決めた構成を使う
GPU の非決定性（同一 seed で最大約 0.7pp ）	全 run の分布で比較し、単一 run の差は主張しない
oseti による明示 / 暗示分割は人手で未検証	限界に明記（検証用サンプル 400 件と採点ツールは準備済み）
2016 年のデータが不完全（約 20% のみ）	データの章に明記
ライセンスデータの本文引用	要確認（ご相談⑤）
一部の分析スクリプトが未整理	執筆前に整理し、保存済みの予測から再計算して照合

スケジュール案（提出日から逆算）

時期	作業	区切り
10 月前半（ 2 週）	RQ4 ・事例分析、図表作成、スクリプト整理	執筆準備の完了
10 月後半〜 11 月	3 〜 5 章（データ・手法・実験）を執筆	11 月末：中間稿を提出
12 月	6 章（分析）、 1 ・ 2 ・ 7 章を執筆	12 月末：全体の初稿
1 月〜	修正、要旨、発表準備	提出日：要確認

・提出日・中間提出の有無が分かり次第、この表を確定します（ご相談④）
・対外発表（言語処理学会 年次大会など）をする場合は、年明けの投稿締切に合わせて 5 章を前倒し

本日ご相談したいこと

論点	選択肢	私の提案
① 主結果の構成	A： XLM-R の主構成を主表、 DeBERTa の積み上げは拡張実験 B： DeBERTa ＋ E7/E8 を主表	A （事前に決めた設定で、最も頑健）
② RQ3 の扱い	A： 否定的な発見として正式に回答 B： 分析の章での議論にとどめる	A （ベースモデルの結果と対比）
③ データ量・年代	A： 分析的実験として報告 B： 主張に含める（ valid で選び直す追加実験が必要）	A
④ 言語・体裁	日本語 / 英語、テンプレート、分量、中間提出日	ご指示ください
⑤ 本文の引用	原文を引用 / 言い換えた例のみ	協定の確認方法をご相談
⑥ 追加実験・発表	追加実験なしで執筆に集中 / 学会発表	追加実験なし。発表はご判断

付録：数値の出典と定義

・すべての数値は docs/thesis_numbers.md に出典（結果ファイル）とともに登録済み

・ネガティブ集約 F1： 7 つのネガティブラベルをまとめて計算した F1 （ラベルごとの F1 の平均ではない）

・有意性： paired bootstrap （ 2,000 回）。複数 seed の比較は seed 平均の予測で検定

・ E1 の 0.7033 と 0.7023 の差：学習時の評価と保存した予測からの再計算で、バッチ処理が異なるため（≤ 0.001 ）

・評価には Gold test （ 5,356 文）のみを使用。パネルとの重複は除外済み