最終学期 第1回 研究報告 ・ 2026年10月1日

報告の台本と想定問答

台本 **p.1〜14**（付録 p.15 は除く）　話す時間の目安 **11:20**（p.14 の相談は別）

想定問答 **33 問**（可能性 高 14 問）

発表の台本

スライドのページ順です。時間はゆっくり読んだときの目安です。p.14 の相談と途中の質問を入れて、全体で20〜30分を想定しています。

- 数字（0.7023 等）幻灯片上都有，慢慢读即可，不用背。
- p.3–9 可以讲快一点；p.10 和 p.14 要放慢。老师开始思考时，安静等待就好，不要抢话。
- 老师中途提问时，先回答问题，再说「では、続けます」回到台本。

p.1　タイトル

0:30　累計 0:30

それでは、最終学期の第1回の研究報告を始めます。

題目はまだ仮題ですが、「評価点を弱教師とした事前学習による、日本語ホテルレビューのアスペクト感情分析」です。

夏学期に実験はすべて終わりましたので、本日は結果のご報告と、論文を書き始める前に決めておきたいことについて、ご相談させてください。

开场：说明实验已全部完成，今天是报告结果+请老师做决定。

p.2 本日の目的

0:40 累計 1:10

本日の流れです。前半では、実験がすべて完了したこと、主な結果、そして当初の仮説と異なった点をご報告します。後半では、修論完成までの計画とリスクをご説明します。

右側の6つが、本日先生に決めていただきたいことです。主結果にどの構成を置くか、RQ3の扱い、データ量と年代の実験の位置づけ、論文の言語や体裁、レビュー本文の引用、そして追加実験や学会発表の要否です。

14ページに選択肢と私の案をまとめていますので、途中でお気づきの点があれば、その都度ご指摘ください。

先亮出 6 个待决事项，请老师随时打断提问。

p.3 研究の問いと手法

1:10 累計 2:20

まず、研究の問いを確認します。Goldデータの感情ラベルのうち、86.5パーセントは感情語を含まない暗示的なものです。ネガティブに限ると、約92パーセントになります。ベースラインのE1では、暗示的なネガティブのF1が、明示的なものより4.3ポイント低くなっていました。

そこで注目したのが、楽天トラベルのレビューに付いている観点別の評価点です。投稿者が立地や部屋などに1から5の点数を付けているので、これを約700万件の弱いラベルとして使うことができます。

手法は2段階です。まずE7で、評価点が1か2のものをネガティブとして、6つの観点のヘッドを事前学習します。次にE8で、そのエンコーダをGoldデータの14ラベルで微調整し、事前学習なしのE1と比べます。

なお、Goldのレビューの約79パーセントがパネルデータにも含まれていることが分かりました。そのため、完全一致と近似重複をあわせて11,369件を除外し、テストの汚染を防いでいます。

回顾问题（隐式负面难）、想法（用评分作弱标签）、两阶段方法、去重。

p.4 夏学期の進捗

0:40 累計 3:00

夏学期の進捗です。データ整備、主実験、分析実験、追加実験まで、予定していた実験はすべて完了しました。

残っているのは、評価点と本文の一致度を見るRQ4の分析と、事例分析の2つです。どちらもGPUを使わない分析なので、執筆前の1週間ほどで終えられる見込みです。

> 实验全部完成；只剩 RQ4 和案例分析，约一周。

p.5 主結果

1:30 累計 4:30

主結果です。XLM-Rで、事前学習なしのE1と、弱教師事前学習ありのE8を比べました。

ネガティブの集約F1は、0.7023から0.7223へ、2.00ポイント改善しました。paired bootstrapによる95パーセント信頼区間はプラス0.80からプラス3.21で、ゼロを含まないので有意です。マイクロF1も有意に改善しましたが、ポジティブには有意な差がありませんでした。

左下は頑健性の確認です。同じ設定、同じseedでも、GPUの非決定性によって結果が最大0.7ポイントほど揺れることが分かりました。そこで、1回の実行ではなく、E1の全7回と、E8の3つのseedの分布で比べました。差はプラス1.60ポイントで、E8の最も低い値でも、E1の最も高い値を上回っています。

ネガティブだけが有意に改善し、ポジティブは変わらないことから、全体の底上げではなく、ネガティブの検出に特に効いていると考えています。

> 主结果 +2.00（bootstrap）/ +1.60（全部运行的分布）；只有负面显著→负面特异。

p.6 観点別の効果

1:00 累計 5:30

どの観点に効いたかを見ると、改善は立地、部屋、設備に集中しています。これらは、パネルに直接対応する評価項目がある観点です。

一方で、朝食と夕食はほとんど改善しませんでした。パネルの評価は「食事」の1項目しかなく、朝食と夕食を区別できないためだと考えています。

また、立地は事前学習のタスクでは最も精度の低いヘッドでしたが、下流では最も大きく改善しました。事前学習タスクの精度と、下流での価値は、必ずしも一致しないということです。

提升集中在有对应评分项的方面；食事粒度不匹配；预训练精度≠下游价值。

p.7 アブレーション

0:50 累計 6:20

アブレーションでは、主構成の選択が妥当かどうかを確認しました。

微調整では、パラメータ全体を更新するのが最も良い結果でした。層別学習率にするとE1とほぼ同じになり、事前学習の利点が消えてしまいます。エンコーダを凍結すると大きく下がります。

事前学習は1エポックでも2エポックとほぼ同じで、総合評価のヘッドを加えても効果はありませんでした。

消融：全参数最好；分层 lr 抵消收益；1 epoch 足够；总合头无用。

p.8 データ量と年代

1:00 累計 7:20

データ量と年代の影響です。全年からランダムに抽出すると、200万件で改善幅が最も大きくなり、676万件ではかえって下がりました。

また、同じ規模でも、2021年から24年の近年のデータではプラス3.12ポイント、2009年から13年のデータではプラス1.55ポイントで、近年のほうが約2倍効いています。評価点の分布は年代によって大きく変わらないので、ラベルではなく、文体などの言語の違いが原因だと考えています。

ただし、これらはそれぞれ1回の実行で、テストデータ上で比べたものです。そのため、最適な構成を選ぶ根拠には使わず、分析として報告したいと考えています。これが、ご相談の3番目です。

200 万最好、676 万下降；近年数据效果约为早年 2 倍；定位为分析性实验。

p.9 ベースモデル比較と積み上げ

1:00 累計 8:20

次に、ベースモデルの比較です。日本語専用のDeBERTaに替えるだけで、ネガティブのF1がプラス1.9ポイント改善し、暗示的なネガティブも有意に改善しました。特に、短い文や否定の形がない文など、手がかりの少ない文で差が大きくなっています。

さらに、DeBERTaの上に弱教師事前学習を重ねても、プラス1.85ポイントの有意な改善がありました。2つの改善は、互いに補い合っていると言えます。

また、対照学習のSCLも試しましたが、BCEより有意に低い結果でした。SCLはレビュー全体の極性という1つの情報しか使わないのに対して、BCEは観点ごとに6つの情報を使えるためだと考えています。

> 换 DeBERTa 本身 +1.9，隐式负面显著；叠加再 +1.85；SCL 反而更差。

p.10 RQごとの回答

1:00 累計 9:20

RQごとの回答です。RQ1とRQ2はYesです。

問題はRQ3です。弱教師事前学習の効果は暗示的なネガティブで特に大きい、という当初の仮説は支持されませんでした。暗示的なネガティブを有意に改善したのは、むしろ日本語専用モデルのほうでした。この扱いについて、後ほどご相談させてください。

RQ4はこれから分析します。RQ5の人手による検証は、以前ご相談したとおり今回は実施せず、限界として書く予定です。

> RQ3 与原假设相反，是今天重点相谈事项。

p.11 論文の構成案

0:30 累計 9:50

論文は、この7章で構成する予定です。ほとんどの章の材料はそろっていて、残りは図表の作成と、6章のRQ4と事例分析です。

> 7 章结构，材料基本齐全。

p.12 リスクと対応

0:50 累計 10:40

リスクと対応です。上の2つは、自分で確認して見つけた点です。

1つ目は、データ量と年代の比較をテストデータで行ったことです。これは分析として扱い、主表には事前に決めた構成を使います。2つ目はGPUの非決定性です。すべての実行の分布で比べ、1回だけの差は主張しません。

そのほか、osetiによる分割が人手で検証されていないこと、2016年のデータが不完全なこと、本文の引用、スクリプトの整理があります。それぞれ対応を決めています。

主动讲出自己查出的两个风险，显示结论经得起追问。

p.13 スケジュール案

0:40 累計 11:20

スケジュール案です。10月前半の2週間で執筆の準備を終え、11月末に3章から5章の中間稿、12月末に全体の初稿を目指します。

提出日と中間提出の有無を教えていただければ、この表を確定させます。

请老师告知提交日和中期节点。

p.14 ご相談したいこと

対話　時間は先生次第

最後に、本日ご相談したいことです。1つずつ伺ってもよろしいでしょうか。

① 1つ目は主結果の構成です。私は、事前に決めた設定で最も頑健な、XLM-Rの主構成を主表にして、DeBERTaの積み上げは拡張実験として示すA案がよいと考えています。先生はいかがお考えでしょうか。

② 2つ目はRQ3です。当初の仮説とは逆の結果になりましたが、否定的な発見として正式に答え、日本語専用モデルの結果と対比させたいと考えています。この書き方で問題ないでしょうか。

③ 3つ目は、データ量と年代の実験です。テストで比べたものなので、分析的な実験として報告したいと考えています。もし主張に含めるべきということでしたら、validで選び直す追加実験が必要になります。

④ 4つ目は、論文の言語と体裁です。日本語と英語のどちらで書くべきか、テンプレートや分量、中間提出の日程について教えていただけますか。

⑤ 5つ目は、レビュー本文の引用です。事例分析でレビューの原文を載せてもよいか、協定の確認方法も含めてご相談させてください。

⑥ 最後に、追加実験と学会発表です。私としては、追加実験はせずに執筆に集中したいと考えています。学会発表については、先生のご判断を伺えればと思います。

締め 本日決めていただいた内容は、整理して後ほどメールでお送りします。ありがとうございました。

逐项询问；老师回答后当场记下；最后说会发邮件整理结论。

想定問答

先生に聞かれそうな質問と回答例です。「可能性 高」から練習してください。「回答を隠す」を押すと回答がぼやけ、タップすると表示されます。

Q1 **可能性 高** 研究の意義・位置づけ

この研究の新規性は何ですか。

你的研究新颖点是什么?

回答例

主に3つあると考えています。1つ目は、レビューに付いている観点別の評価点を、文単位のABSAの事前学習に使えることを、有意性の検定つきで示したことです。

2つ目は、どの観点に効くかが評価項目の有無で決まること、つまり評価点の粒度が効果を左右することを示したことです。

3つ目は、データ量には最適な範囲があり、テストに近い年代のデータほど効果が大きいことを示したことです。

三点：评分弱监督有效且显著；效果取决于评分项粒度；数据量有最优区间、年份越近越有效。

Q2 **可能性 高** 研究の意義・位置づけ

ドメイン適応の事前学習（DAPT）や、既存の弱教師の研究とは何が違うのですか。

和 DAPT、已有弱监督研究（DSPN、SCAPT）有什么不同?

回答例

DAPTは、ラベルなしのテキストでマスク言語モデルを続けて学習する方法です。本研究は、同じドメインのテキストを使いつつ、観点別の評価点という弱いラベルを使う点が違います。

既存の研究の多くは、レビュー全体の星評価を1つのラベルとして使っています。本研究では観点ごとに6つのラベルを使いました。実際に、文書全体の極性だけを使うSCLと比べると、観点別のBCEの方が有意に良い結果でした。

DAPT 用无标签 MLM；我们用方面级评分。已有研究多用整体星级；我们用 6 个方面，并用 SCL 对照证明了方面级更好。

Q3 可能性 中 研究の意義・位置づけ

1.6ポイントの改善は、実用上意味のある大きさですか。

提升 1.6 个点在实用上有意义吗?

回答例

ネガティブのラベルはもともと少なく、改善が難しい部分なので、意味のある差だと考えています。特に立地や部屋では5から7ポイント改善しています。

また、追加のアノテーションは不要で、すでにある評価点だけで得られる改善なので、コストの面でも利点があります。さらに、日本語専用モデルと組み合わせると、合計で3.8ポイントの改善になります。

负面本来难提升；立地/部屋提升 5–7 点；无需额外标注；与日语模型组合累计 +3.8。

Q4 可能性 高 データ

評価点をラベルにして大丈夫ですか。評価点と本文の内容が一致しない場合もあるのではないですか。

用评分当标签可靠吗？评分和正文不一致怎么办?

回答例

おっしゃるとおり、評価点と本文が一致しないケースはあると思います。そのため、評価点は正解ではなく、ノイズを含む弱いラベルとして扱い、最終的にはGoldデータで微調整しています。

どの程度一致しないかは、RQ4としてこれから分析し、論文に数字を載せる予定です。ノイズがあっても下流で有意に改善したこと自体が、弱いラベルとしての有用性を示していると考えています。

承认有噪声；当弱标签用，最终靠 Gold 微调；RQ4 会量化；有噪声仍有效本身就是证据。

Q5 可能性 高 データ

ネガティブの基準はどう決めましたか。評価点3はどう扱っていますか。

负面的阈值怎么定的？3 分怎么处理？

回答例

評価点が1か2のものをネガティブ、3から5をネガティブでないもの、評価なしの0はその観点の損失から除外しています。

3は中立に近いですが、ネガティブではないとして扱いました。3を除外する設定との比較は行っていないので、必要であれば今後の課題として書きます。

1–2=负，3–5=非负，0=不计损失。3 分未做排除对比，可作未来课题。

Q6 可能性 高 データ

レビュー単位の評価点で、文単位のABSAを学習して問題ありませんか。

用评论级评分训练句子级 ABSA 没问题吗？

回答例

粒度が違うことは、ご指摘のとおり限界の1つです。ただ、E7はあくまで事前学習で、文単位の判断はGoldデータでの微調整で学習しています。

実際に、評価項目と観点が一致する立地や部屋では大きく改善し、食事を朝食と夕食に分けられない観点では改善しなかったので、粒度の影響は結果にも表れています。論文では限界として議論します。

粒度不匹配是局限；E7 只是预训练，句级判断靠微调；朝夕食结果正好体现粒度影响。

Q7 可能性 高 データ

パネルとGoldの重複は、本当に除けていますか。

面板和 Gold 的重复真的去干净了吗?

回答例

2段階で確認しました。まず、テキストのハッシュで完全一致を探し、9,911件のGoldレビューがパネルに含まれていることが分かりました。

次に、MinHashを使って、Jaccard係数0.85以上の近似重複を探し、さらに1,458件を見つけました。合計11,369件を事前学習のデータから除外しています。また、テストデータは事前学習にも重複チェックにも使っていません。

精确哈希 9,911 + MinHash 近似 1,458 = 11,369 件全部剔除；test 从不参与训练。

Q8 可能性 中 データ

Goldデータの分割はどうなっていますか。同じレビューの文が学習とテストに分かれていませんか。

Gold 怎么划分的？同一评论的句子会不会跨 train/test?

回答例

レビューIDの単位で分割しているので、同じレビューの文が学習とテストに分かれることはありません。

文の数は、学習が42,469、検証が5,367、テストが5,356です。

按 review_id 分组划分，无泄漏。42,469 / 5,367 / 5,356 句。

Q9 可能性 低 データ

2016年のデータはどうなっていますか。

2016 年的数据是怎么回事?

回答例

2016年の元のファイルは途中で切れていて、約8万件、本来の2割ほどしか読めませんでした。読める部分だけを使っており、論文のデータの章に明記します。

主な結果は2024年のデータと、2021年から24年のデータで得ているので、結論への影響は小さいと考えています。

原始文件截断，只救回约 8 万条；主结论不依赖 2016 年。

Q10 可能性 高 手法

なぜ最初からDeBERTaではなく、XLM-Rを使ったのですか。

为什么一开始用 XLM-R 而不是 DeBERTa?

回答例

研究を始めた時点のベースラインがXLM-Rだったので、比較の条件をそろえるために、主実験はXLM-Rで行いました。

その後、ベースモデルの影響を確かめるために日本語専用モデルと比較し、DeBERTaの上でも弱教師事前学習が有意に効くことを確認しています。

早期基线就是 XLM-R，为保持对照一致；后来补了日语模型对比，叠加仍显著。

Q11 可能性 中 手法

ASLを使った理由は何ですか。

为什么用 ASL 损失?

回答例

14ラベルのマルチラベル分類で、特にネガティブのラベルが少なく、不均衡が大きいためです。

ASLは、簡単な負例の損失を小さくして、少ない正例に学習を集中させる損失関数です。E1とE8は、同じASLの設定で比べています。

多标签且负面稀少、严重不平衡；ASL 降低易负例权重。E1/E8 设定相同。

Q12 可能性 高 手法

閾値はどのデータで決めましたか。テストで調整していませんか。

阈值用哪份数据调的？有没有在 test 上调?

回答例

閾値はラベルごとに、検証データで決めています。テストデータは最後の評価にだけ使っています。

每个标签的阈值在 valid 上调，test 只用于最终评估。

Q13 可能性 低 手法

なぜ総合評価のヘッドを入れないのですか。

为什么不加总合评分头?

回答例

総合評価のヘッドを加えた7ヘッドの設定も試しましたが、下流の結果はほぼ同じでした。総合評価は観点の情報を持たないので、観点別の分類には役立たないと考えています。

试过 7 头，结果几乎相同；总合评分不含方面信息。

Q14 可能性 高 結果・統計

1.6ポイントの差は、誤差の範囲ではありませんか。

1.6 个点会不会只是误差?

回答例

その点は2つの方法で確認しました。1つ目はpaired bootstrapで、信頼区間がゼロを含まず、有意でした。

2つ目は、実行ごとのばらつきです。同じseedでも最大0.7ポイントほど揺れることが分かったので、E1の7回とE8の3回の分布で比べました。E8の最も低い値でも、E1の最も高い値を上回っています。

bootstrap 显著 + 7 次 vs 3 次分布：E8 最差 > E1 最好。

Q15 可能性 中 結果・統計

paired bootstrapとは何ですか。

paired bootstrap 是什么?

回答例

テストデータから、重複を許して同じ数の文をランダムに選び直し、2つのモデルを同じ標本で評価して差を計算します。これを2,000回繰り返して、差の95パーセント信頼区間を求めます。

同じ標本で比べるので、テストデータの偏りの影響が打ち消され、差を正確に評価できます。

有放回重采样 test，两模型在同一样本上算差值，重复 2000 次得 95% CI。

Q16 可能性 中 結果・統計

seedが3つでは少なくありませんか。

3 个 seed 会不会太少?

回答例

はい、多いとは言えません。そのため、seedだけでなく、E1は7回の実行を使い、bootstrapとあわせて2つの方法で確認しました。

時間があればseedを増やすこともできますが、結論の方向は変わらないと考えています。先生が必要だと判断されれば追加します。

承认偏少；用 7 次 E1 + bootstrap 双重验证；老师要求可补。

Q17 可能性 中 結果・統計

なぜポジティブは改善しないのですか。

为什么正面没有提升?

回答例

E7では、評価点の低いものをネガティブとして学習しているので、事前学習はネガティブの信号に集中しています。

また、ポジティブのラベルはもともと数が多く、E1でもF1が0.86と高いので、改善の余地が小さいと考えています。

E7 只学负面信号；正面本身数据多、F1 已高（0.86）。

Q18 可能性 中 結果·統計

立地の改善が最も大きいのはなぜですか。

为什么立地提升最大?

回答例

立地はGoldのテストでネガティブが125件と最も少なく、E1ではほとんど学習できていませんでした。

パネルには立地の評価点が直接あるので、少ないGoldデータを事前学習の信号が補ったためだと考えています。

立地负例最少（125），E1 学不到；面板有直接评分补足了信号。

Q19 可能性 中 結果·統計

層別学習率にすると、なぜ事前学習の利点が消えるのですか。

为什么分层学习率会让收益消失?

回答例

はっきりした原因はまだ分かっていません。考えられるのは、事前学習で得た表現をGoldのタスクに合わせるには、エンコーダを十分に更新する必要があり、エンコーダの学習率を下げるとそれができなくなる、ということです。

論文では、観察された事実として報告し、原因は仮説として書く予定です。

原因未确定；推测需要充分更新 encoder；论文中作为观察+假设。

Q20 可能性 高 結果・統計

676万件で下がったのはなぜですか。

676 万反而下降，原因是什么?

回答例

最初は古い年代のデータが原因だと考えましたが、年代別に全件を調べると、評価点の分布に大きな違いはありませんでした。

下がった幅は0.7ポイントで、同じseedでの実行のばらつきと同じくらいなので、単なるばらつきの可能性もあります。原因は確定できていないので、論文では断定しない書き方にします。

查过标签分布无异常；下降 0.7 与同 seed 噪声同量级，可能只是波动；不下定论。

Q21 可能性 中 結果・統計

年代の効果は、本当に文体の違いによるものですか。

年份效应真的是文体差异造成的吗?

回答例

評価点の分布は年代によって大きく変わらないことを確認したので、ラベルの違いではないと考えています。そのうえで、テストに近い年代のデータほど効果が大きいので、言語の違いが原因と考えるのが自然です。

ただし、文体の違いを直接測ったわけではないので、論文では解釈として書きます。必要であれば、年代ごとの語彙の分布を比べる分析を加えることができます。

排除了标签分布原因；但未直接测文体，作为解释来写；可补词汇分布分析。

Q22 可能性 高 結果·統計

テストデータを見て構成を選んだことになりませんか。

这不就等于看着 test 选配置了吗?

回答例

ご指摘のとおりです。データ量と年代の実験は、テストで比べたものなので、最適な構成の選択には使わず、分析として報告します。

主表には、実験の前に決めていた2024年データの主構成を使います。どうしても主張に含める場合は、検証データで選び直す追加実験が必要です。

承认；数据量/年份实验仅作分析；主表用事先确定的配置。

Q23 可能性 高 暗示的表現·RQ3

明示と暗示は、どうやって区別したのですか。

显式和隐式是怎么区分的?

回答例

感情辞書を使うosetiで、文の中に感情語があるかどうかを判定し、感情語がない文のラベルを暗示的としています。

この分割は人手では検証できていないので、論文の限界として書きます。検証用の400件のサンプルと採点のツールは準備してあるので、将来はすぐに検証できます。

用 oseti 感情词典判断是否含感情词；未人工验证，写进局限；验证样本和工具已就绪。

Q24 可能性 高 暗示的表現・RQ3

RQ3が否定されると、研究の主張が弱くなりませんか。

RQ3 被否定，研究主张会不会变弱?

回答例

主張の中心はRQ2で、弱教師事前学習がネガティブの検出を有意に改善することは確かめられています。

RQ3については、弱教師事前学習の効果は暗示に特有のものではなく、暗示の理解には日本語専用モデルの方が効く、という新しい知見が得られました。2つの改善が互いに補い合うことも示せたので、否定的な結果も含めて、研究全体としてはむしろ説明が明確になったと考えています。

主张核心是 RQ2（已验证）；RQ3 得到新知见：弱监督非隐式特异、日语模型才改善隐式，两者互补。

Q25 可能性 中 暗示的表現・RQ3

なぜ日本語専用モデルは暗示的な表現に強いのですか。

为什么日语专用模型更擅长隐式表达?

回答例

分析すると、DeBERTaの優位は、否定の形がない文や短い文など、表面的な手がかりが少ない文で大きくなっていました。

日本語専用の大量のテキストで学習しているので、日本語の言い回しや語用的な意味をよく捉えられるためだと考えています。

优势集中在无否定形态、短句等线索少的句子；日语语料带来更好的语用理解。

Q26 可能性 中 暗示的表現・RQ3

暗示と明示の差が縮まったとは言えないのですか。

不能说隐式-显式差距缩小了吗?

回答例

点推定では縮まっていますが、有意ではありませんでした。ネガティブの約92パーセントが暗示的で、明示的なネガティブが147件しかないため、差の推定が不安定になるからです。

そのため論文では、差が縮まったとは主張せず、暗示的なネガティブのF1が有意に改善した、という形で書きます。

点估计缩小但不显著；显式负面仅 147 对；只主张隐式 F1 显著提升。

Q27 可能性 高 比較・追加実験

GPTなどのLLMと比較しないのですか。

不和 GPT 等大模型比较吗?

回答例

今回の研究の範囲は、小さいモデルを事前学習で改善することなので、LLMとの比較は今後の課題としています。

ただ、審査で必要だとご判断されれば、テストの一部を使って、LLMのゼロショットの結果を小規模に比べることは可能です。

范围是小模型+预训练，LLM 列为未来课题；老师要求可小规模补 zero-shot 对比。

Q28 可能性 中 比較·追加実験

SCLを試した理由と、うまくいかなかった理由を教えてください。

为什么试 SCL？为什么失败?

回答例

英語の研究で、星評価を使った対照学習が暗示的な感情に効くと報告されていたので、本研究でも上位の方法になるかを確かめました。

結果はBCEより有意に低く、事前学習なしとほぼ同じでした。SCLはレビュー全体の極性という1つの情報しか使わないのに対して、BCEは観点ごとに6つの情報を使えるためだと考えています。

英文研究（SCAPT）报告有效，故验证；结果更差，因为 SCL 只有 1 个整体极性信号。

Q29 可能性 中 比較·追加実験

DeBERTaが一番良いなら、それを主結果にすべきではありませんか。

DeBERTa 最好，为什么不作主结果?

回答例

数字は一番大きいですが、DeBERTaの実験は研究の途中で追加したもので、事前学習のデータも近年の200万件と、主実験とは条件が違います。

事前に決めた条件で比較したXLM-Rの結果を主表にし、DeBERTaは拡張として示す方が、主張として頑健だと考えています。ただ、先生のご意見を伺って決めたいと思います。

DeBERTa 是后加的、条件不同；事先确定的 XLM-R 更稳健；听老师意见。

Q30 可能性 中 今後·執筆

スケジュールは間に合いますか。

进度来得及吗?

回答例

実験はすべて終わっていて、残りは分析2つと執筆なので、間に合う見込みです。

提出日が分かれば逆算して、11月末の中間稿、12月末の初稿という区切りを確定させます。遅れそうな場合は早めにご相談します。

实验已完成，只剩分析和写作；按提交日倒推确定节点；如有延误提前报告。

Q31 可能性 中 今後·執筆

データやコードは公開できますか。

数据和代码可以公开吗?

回答例

パネルデータはNII-IDRの利用規約のもとで使っているので、データそのものは公開できません。

コードと、実験の結果、評価に使った数値は公開できる形で整理しています。レビュー本文の引用については、規約の確認が必要なので、本日ご相談させてください。

面板数据受 NII-IDR 规约限制不能公开；代码和结果可以；本文引用需确认。

Q32 可能性 低 今後・執筆

再現性はどう確保していますか。

怎么保证可复现?

回答例

実験ごとにseedと設定を記録し、主な実験のテストの予測を保存しているので、検定は再計算できます。

論文の数字は、すべて出典のファイルと対応させた台帳で管理しています。ただ、GPUの非決定性があるので、同じseedでも完全には一致しないことを論文に書きます。

记录 seed/配置、保存预测可复算、数字台账管理；注明 GPU 非确定性。

Q33 可能性 低 今後・執筆

計算にはどのくらい時間がかかりましたか。

计算花了多长时间?

回答例

研究室のGPU 1枚で行いました。事前学習は、200万件で1エポック約1.5時間です。微調整は1回数分で終わります。

正確な時間は、論文を書くときに記録から整理して載せます。

单卡（RTX 6000 Ada）；200 万条预训练 1 epoch 约 1.5 小时，微调一次几分钟。

困ったときの一言

答えに詰まったときは、無理に答えず、この言い方で時間を取ってください。

質問が聞き取れなかったとき

すみません、もう一度おっしゃっていただけますか。

没听清时

質問の意図を確認したいとき

ご質問は、〇〇ということでよろしいでしょうか。

确认问题意图

すぐに答えられないとき

今すぐ正確にはお答えできないので、確認して後日ご報告します。

答不上来时（不要硬答）

指摘を受け入れるとき

ご指摘ありがとうございます。その点は論文の限界として書きます。

接受批评

反対の意見を伝えたいとき

おっしゃることはよく分かります。ただ、〇〇という理由で、私は〇〇がよいと考えているのですが、いかがでしょうか。

委婉表达不同意见

先生が決めてくださったとき

承知しました。では、〇〇の方向で進めます。

老师拍板后确认

考える時間がほしいとき

少し考えさせてください。

需要思考时间

会の終わり

本日決めていただいた内容は、整理して後ほどメールでお送りします。ありがとうございました。

结束时