研究進捗報告

評価点を弱教師とした事前学習による日本語ホテルレビューのアスペクト感情分析

— 研究の現状と論文化の見通し —（題目は仮）

2026 年 10 月 15 日
GU JINCHENG

本日の報告

結論

予定していた実験はすべて完了し、論文として書ける段階に来ています。

実験はここで締めて、執筆に移りたいと考えています。

本日の内容

1. 研究の概要
2. 主な結果（4 点）
3. 効く条件と限界
4. 論文の構成と計画
5. ご相談したいこと

研究の概要

課題

・文ごとに「どの観点について、肯定か否定か」を判定する（7 観点 × 正負＝14 ラベル）

・ネガティブはラベル全体の 26% しかない

・ネガティブの 92% は、感情辞書の否定語を含まない（暗示的）

・例：「駅から歩いて 20 分かかった。」→ 立地・ネガティブ（説明用の作例）

アイデア

・楽天トラベルのレビューには、投稿者が付けた観点別の評価点がある（6 観点、1 〜 5 点）

・約 700 万件。追加のアノテーション費用はかからない

・これを弱い教師信号として使う

手法と評価

・① 評価点で事前学習：1 〜 2 点をネガティブ、3 〜 5 点をそれ以外、未評価は学習に使わない

・② 人手ラベルの Gold データ（53,192 文）で微調整

・比較対象：①なしで②だけ（事前学習なし）

・評価：テスト 5,356 文のネガティブ集約 F1 。複数回の実行と paired bootstrap で 95% 信頼区間

Gold： Nakayama et al.（LREC 2022）。評価点データ：楽天トラベル 2009 〜 2024 年（国立情報学研究所 IDR 経由で提供）。 Gold と重複するレビューは除外。

主結果（XLM-R base）

結果① 評価点による事前学習はネガティブの検出を改善する

指標（テスト）	事前学習なし（5回）	事前学習あり（9回）	差	95% 信頼区間
ネガティブ集約 F1	0.7066	0.7257	+1.91	[+1.10, +2.75]
暗示的ネガティブ（2,065）	0.8403	0.8546	+1.43	[+0.69, +2.18]
ポジティブ集約 F1	0.8605	0.8623	+0.17	有意差なし

・事前学習ありの9回すべてが、事前学習なしの最高値（0.7143）を上回る

・観点別：立地 +6.07、風呂 +4.06、部屋 +3.56、設備 +2.42（有意）。サービス・朝食・夕食は有意差なし

・適合率と再現率がともに改善し、ネガティブと予測する数はほぼ同じ（2,353 → 2,363）

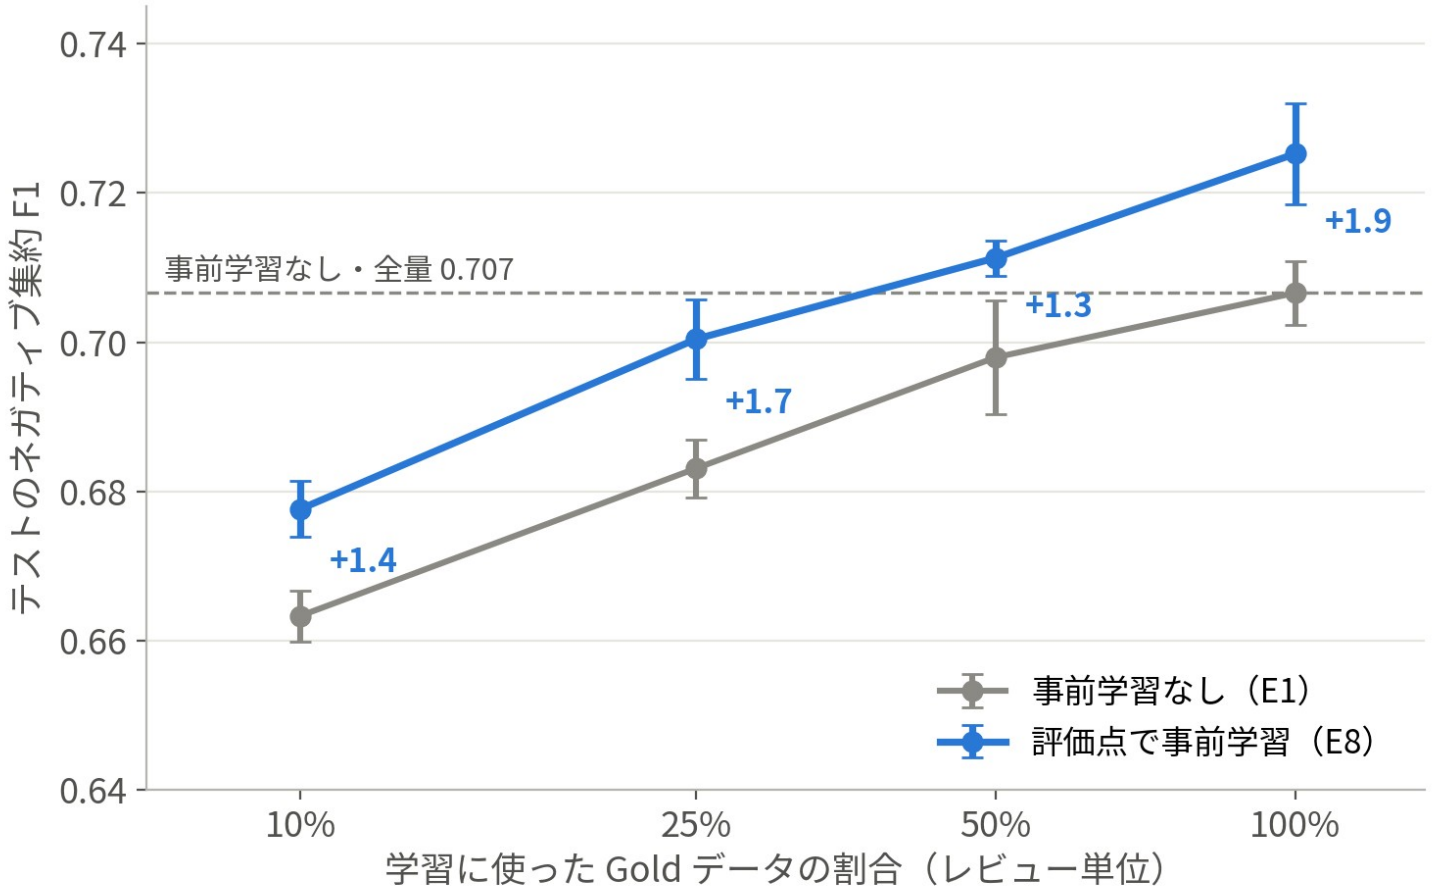
読み取れること

改善はネガティブに限られる。

Gold で数が少ないクラスを、評価点が補っている。

新規：ラベル量を変えた実験

結果② 人手ラベルが半分でも、事前学習なし・全量と同程度



・Gold の量を 10 〜 100% に変えても、改善幅は約 1.3 〜 1.9 ポイントでほぼ一定

・事前学習ありなら Gold 50% でも、事前学習なし・全量と有意差なし（ +0.47 、信頼区間は 0 を含む）

・内挿すると約 37% で全量の水準に届く（参考値）

意味

評価点を使えば、人手ラベルを約半分に減らしても同じ水準を保てる。

各点 5 回の平均（ひげは標準偏差）。少量データで基線が学習不足にならないよう、更新回数を全量とそろえた設定（検証データで選択）。

新規：信号の種類だけを変えた対照実験

結果③ 効いているのは「観点別」の評価点

DeBERTa ・ 2021 ～ 24 年のデータ	観点別の評価点（6 出力）	総合評価点のみ（1 出力）
二値分類（ BCE ）	0.7447 事前学習なしより +1.85	0.6818 事前学習なしより − 4.44
対照学習（ SCL ）	未実施	0.7259 事前学習なしより − 0.03

事前学習なし： 0.7262 （テストのネガティブ集約 F1 、各 3 回）

・同じ学習方法のまま、信号を総合評価点に替えると、改善が消えるだけでなく悪化する（− 4.44 、有意）

・観点別と総合の差： +6.29 （ DeBERTa ）、+3.82 （ XLM-R ）。 DeBERTa では 7 観点すべてで観点別が上

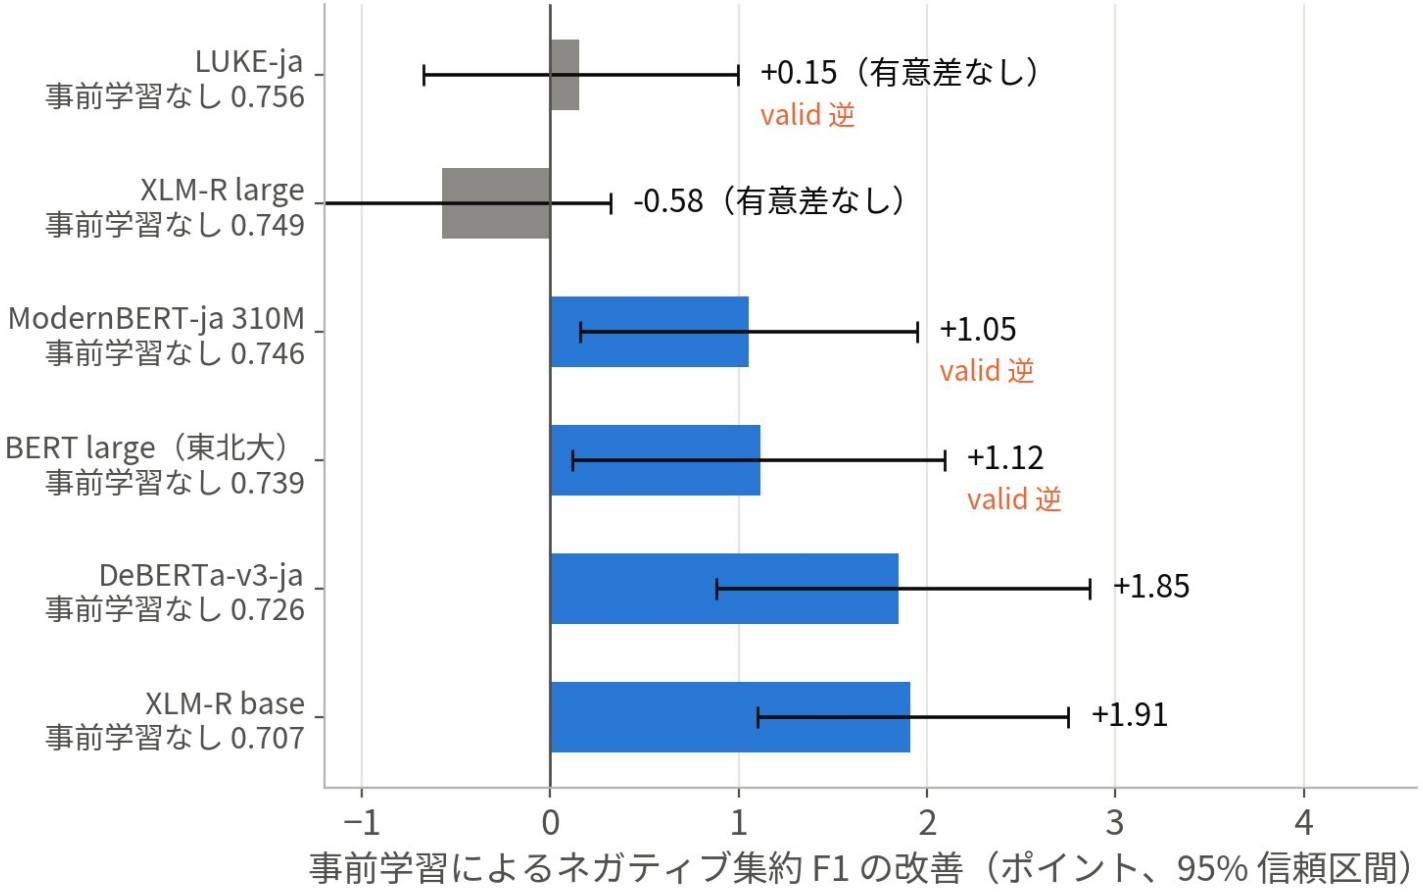
・総合評価点だけなら対照学習の方が良い（ +4.41 ）。「二値分類が優れている」とは言えない

読み取れること

効いているのは「どの観点が悪かったか」という情報。総合評価点のマルチタスク学習に効果がなかった先行研究（小泉 2025 ）とも整合する。

新規： 6 種類のモデルで検証

結果④ 強いモデルほど改善は小さく、最も強いモデルでは消える



・比較的弱いモデル（ XLM-R base 、 DeBERTa ）では明確に改善（約 +1.9 ）

・ BERT large と ModernBERT はテストでは有意だが、検証データでは逆方向

・ XLM-R large と、最も強い LUKE-ja では効果なし（ -0.58 、 +0.15 、いずれも有意差なし）

・同じ XLM-R でも、 base は +1.91 、 large は -0.58

論文での書き方

「どのモデルでも効く」とは書かない。強いモデルでの限界として明記する。

事前学習なしの値が大きいほど強いモデル。 XLM-R base と DeBERTa は主結果・既存の比較、その他は 3 回ずつ。

同じデータ分割・同じ評価指標

他のモデルとの比較

種類	モデルとテストのネガティブ集約 F1
微調整したエンコーダ （事前学習なし、各 3 回）	mBERT 0.662 / XLM-R base 0.708 / DeBERTa-v3-ja 0.724 / BERT large 0.739 ModernBERT-ja 310M 0.746 / XLM-R large 0.749 / LUKE-ja 0.756
＋評価点による事前学習	XLM-R base 0.726 / DeBERTa-v3-ja 0.745 / BERT large 0.750 ModernBERT-ja 310M 0.756 / LUKE-ja 0.757 / XLM-R large 0.743
ローカル LLM （学習なし、指示＋ 20 例）	llm-jp-3.1-13B 0.489 / Qwen2.5-7B 0.597 / gpt-oss-20B 0.613 / Swallow-8B 0.629

・モデルの違い（約 9 ポイント）は、事前学習による改善（1 ～ 2 ポイント）より大きい

・ LLM は学習なしでは、最も古典的な mBERT にも届かない。 GPT-4o 等の外部サービスはデータ利用規約のため未使用（ご相談事項）

事前学習なしのエンコーダは比較実験での再実行（3 回）。主結果（5 回）とは実行が異なる。 LLM は各モデルの良い方の設定。

効く条件と、効かなかった試み

変えた条件	結果（事前学習なしとの差、ポイント）	分かったこと
事前学習のデータ量： 58 万 / 200 万 / 676 万件	+1.0 / +3.1 / +2.4 （各 1 回）	約 200 万件で頭打ち
データの年代： 2021 〜 24 年 / 2009 〜 13 年	+3.1 / +1.6 （各 1 回）	新しいデータほど有効
本文に観点の語がある低評価だけを残す	−1.08 （有意）	ノイズ除去はかえって有害
食事の評価点を朝食・夕食に分ける	朝食 − 0.71 、夕食 − 0.16 （ 5 回、有意差なし）	分けても改善しない
改善が起きた文の分析（ 3 モデル）	暗示的ネガティブ全般で改善 純粋に暗示的な文も +1.7 前後	特定の種類の文に集中してはいない

データ量・年代は各 1 回の実行のため参考扱い。同じ設定でも実行ごとに最大約 0.7 ポイントの揺れがある。

限界

1. 強いモデルでは効果が小さい、または無い（ XLM-R large 、 LUKE-ja ）
2. 暗示的・明示的の区別は感情辞書による自動判定で、人手による検証はしていない
3. データセットは 1 つ（楽天トラベルのホテルレビュー）
4. サービス・朝食・夕食は改善しない（食事の評価点は 1 項目しかない）
5. データ量・年代の実験は各 1 回のみ
6. LLM との比較はローカルモデル（ 7B ～ 20B 、学習なし）に限られる

論文にできるか — 構成と計画

判断：論文にできると考えます

主張 3 点（効果・ラベル効率・観点別の信号）が、事前に決めた検定で支持された

限界も実験で明らかになっている

すべての数字は、保存した予測から再計算できる

スケジュール案（英語で執筆）

- 10 月後半：図表の作成、 3 〜 5 章
- 11 月末：中間稿　／　12 月末：初稿
- 提出日に合わせて調整します

章（英語）	内容
1 Introduction	課題と貢献
2 Related Work	ABSA 、弱教師、暗示的感情
3 Data	Gold と評価点データ、重複除去
4 Method	2 段階の学習
5 Experimental Setup	指標、複数回実行と検定
6 Results	主結果、ラベル効率、信号、モデル
7 Analysis	条件、改善の出どころ、 LLM 比較
8 Discussion	解釈と限界
9 Conclusion	まとめと今後の課題

ご相談したいこと

1. 実験をここで締めて、執筆に移ってよいでしょうか
- 残る候補：観点別評価点＋対照学習、データ量実験の回数追加、暗示・明示の人手検証

2. 「強いモデルでは効果がない」ことを、論文でどの程度前面に出すべきでしょうか

3. GPT-4o 等の外部 API との比較：規約上、楽天の許可が必要です。申請すべきでしょうか

4. データ利用規約について
- 論文・発表の前の楽天への通知、研究終了時のデータ削除
- 開発中、 AI コーディング支援ツールの出力にレビュー本文が一部表示された件の扱い

5. 題目、提出日、発表時間