研究進捗報告・2026年10月15日

報告の台本と想定問答

台本 p.1〜12　話す時間の目安 10:30（p.12 の相談は別）　想定問答 15 問（可能性 高 4 問）

発表の台本

スライドのページ順です。時間はゆっくり読んだときの目安です。p.12 の相談と途中の質問を入れて、全体で 25〜35分を想定しています。

- 数字（0.7066 等）幻灯片上都有，慢慢读即可，不用背。
- p.5–7 是这次的新结果，要放慢；p.12 是商量，一条一条等老师回答。老师开始思考时，安静等待就好，不要抢话。
- 老师中途提问时，先回答问题，再说「では、続けます」回到台本。

p.1　タイトル

0:20　累計 0:20

それでは、研究の進捗をご報告します。題目はまだ仮題ですが、「評価点を弱教師とした事前学習による、日本語ホテルレビューのアスペクト感情分析」です。

> 那么，我来汇报研究的进展。题目还是暂定的，是「以评分为弱监督的预训练：日语酒店评论的方面情感分析」。

本日は、研究が今どこまで進んでいるか、論文として書ける段階にあるか、そしてご相談したいことについてお話しします。

> 今天想讲三件事：研究现在进行到哪一步，是否已经到了可以写成论文的阶段，以及想和老师商量的事情。

开场：今天讲研究进展、能否写成论文、要商量的事。

p.2 本日の報告

0:30 累計 0:50

先に結論を申し上げます。予定していた実験はすべて完了し、論文として書ける段階に来ていると考えています。実験はここで締めて、執筆に移りたいと考えています。

> 先说结论。原定的实验已经全部完成，我认为已经到了可以写成论文的阶段。想在这里结束实验，转入写作。

このあと、研究の概要、主な結果を4つ、効く条件と限界、論文の構成と計画の順にご説明し、最後にご相談したいことをお話しします。

> 接下来按照研究概要、四个主要结果、起作用的条件与局限、论文的结构与计划的顺序说明，最后讲想商量的事情。

先说结论：实验完成，可以写，想转入写作。然后说明流程。

p.3 研究の概要

1:15 累計 2:05

まず研究の概要です。アスペクト感情分析は、レビューの文ごとに、どの観点について肯定しているか、否定しているかを判定するタスクです。本研究では、7つの観点と、肯定・否定の組み合わせで、14のラベルを扱います。

> 首先是研究概要。方面情感分析，是对评论中的每个句子，判断它对哪个方面是肯定还是否定的任务。本研究处理 7 个方面与肯定、否定的组合，共 14 个标签。

難しいのはネガティブです。人手でラベルを付けたGoldデータでは、ネガティブはラベル全体の26パーセントしかありません。さらに、ネガティブの92パーセントは、感情辞書の否定的な語を含まない、暗示的な表現です。たとえば「駅から歩いて20分かかった」という文には不満を表す語がありませんが、立地への不満です。

> 难点在负面。在人工标注的 Gold 数据中，负面只占全部标签的 26%。而且负面中有 92% 是不含情感词典中负面词的隐式表达。比如「从车站走了二十分钟」这句话里没有表示不满的词，但它是对位置的不满。

そこで注目したのが、楽天トラベルのレビューに付いている観点別の評価点です。投稿者が立地や部屋などに1から5の点数を付けていて、約700万件あります。追加のアノテーション費用はかかりません。

> 于是我们注意到乐天旅行评论附带的分项评分。投稿者会给位置、房间等打 1 到 5 分，这样的评论约有 700 万条，不需要额外的标注费用。

手法は2段階です。まず、評価点が1点か2点のものをネガティブとして、モデルを事前学習します。次に、Goldデータで通常どおり微調整します。比較対象は、事前学習をせずにGoldだけで学習したモデルです。評価はテスト5,356文のネガティブ集約F1で、複数回の実行とpaired bootstrapで95パーセント信頼区間を求めています。

> 方法分两个阶段。首先，把评分为 1 分或 2 分的当作负面，对模型进行预训练。然后，用 Gold 数据按通常的方式微调。比较对象是不做预训练、只用 Gold 训练的模型。评价指标是测试集 5,356 句上的负面聚合 F1，并通过多次运行和 paired bootstrap 求出 95% 置信区间。

ABSA 定义；负面少（26%）且 92% 隐式（例句是自己造的）；分项评分约 700 万条、零成本；两阶段方法与评价方式。

p.4 結果①主結果

1:15 累計 3:20

1つ目の結果は主結果です。XLM-Rで、ネガティブ集約F1は0.7066から0.7257へ、1.91ポイント改善しました。95パーセント信頼区間はプラス1.10からプラス2.75で、ゼロを含みません。事前学習ありの9回の実行は、すべて事前学習なしの最高値を上回っています。

> 第一个结果是主结果。在 XLM-R 上，负面聚合 F1 从 0.7066 提高到 0.7257，提高了 1.91 个点。95% 置信区间是 +1.10 到 +2.75，不包含 0。有预训练的 9 次运行，全部高于无预训练的最高值。

暗示的なネガティブも1.43ポイント改善し、有意でした。一方で、ポジティブはほとんど変わりませんでした。

> 隐式负面也提高了 1.43 个点，同样显著。另一方面，正面几乎没有变化。

観点別では、立地、風呂、部屋、設備が有意に改善し、サービス、朝食、夕食は有意な差がありませんでした。

> 按方面看，位置、浴场、房间、设备显著提高；服务、早餐、晚餐没有显著差异。

また、適合率と再現率がともに上がっており、ネガティブと予測する数はほとんど変わっていません。つまり、ネガティブを多めに出すようになったのではなく、判定が正確になったということです。Goldで数が少ないネガティブを、評価点が補っていると考えています。

> 另外，精确率和召回率都提高了，而预测为负面的数量几乎没有变化。也就是说，不是模型变得更爱输出负面，而是判断变得更准确了。我认为，是评分弥补了 Gold 中数量少的负面。

主结果 +1.91 显著，9 次全高于基线最高值；隐式 +1.43；正面不变；精确率和召回率都升，不是多报负面。

p.5 結果② ラベル効率

1:20 累計 4:40

2つ目は、今回 新しく行った、ラベルの量を変えた実験です。Goldの学 習データを、レビュー単位で10パーセント、25パーセント、50パーセントに減らして、事前学 習ありとなしを、それぞれ5回ずつ比較しました。

> 第二个是这次新做的、改变标注量的实验。把 Gold 训练数据按评论为单位减少到 10%、25%、50%，有预训练和无预训练各跑 5 次进行比较。

グラフのとおり、どの量でも改善は1.3から1.9ポイントで、ほぼ一定でした。そして、事前学 習ありならGoldが50パーセントでも、事前学 習なしで全 量を使った場合と有意な差がありません。内挿すると、約37パーセントで全 量の水 準に届きます。

> 如图所示，无论哪个数据量，提高幅度都在 1.3 到 1.9 个点之间，基本恒定。而且，有预训练时即使 Gold 只有 50%，与无预训练使用全量的情况也没有显著差异。插值估计，约 37% 就能达到全量的水平。

つまり、評価点を使えば、人手ラベルを約半分に減らしても同じ水 準を保てる、ということです。これが、この研 究の実用的な意味だと考えています。

> 也就是说，使用评分的话，即使把人工标注减少到大约一半，也能保持同样的水平。我认为这是本研究的实用意义。

なお、学 習 回数について1点補足します。データを減らしたまま学 習 回数を固定すると、事前学 習なしのモデルが学 習 不足になり、10パーセントで5ポイントの差が出ます。これは見かけの差なので、検 証データに基づいて、更新回数を全 量とそろえた設定を採用しました。この選び方は、実験の前に決めておきました。

> 另外，关于训练轮数补充一点。如果减少数据却固定训练轮数，无预训练的模型会训练不足，在 10% 时会出现 5 个点的差。这是表面上的差，所以我们根据验证数据，采用了让更新次数与全量相同的设定。这个选择方法是在实验之前就定好的。

新实验：Gold 减到 10/25/50%；增益恒定约 1.3–1.9；有预训练时一半 Gold 与无预训练全量无显著差（插值约 37%）→ 能省一半标注。固定轮数会夸大到 +5，按事先定的规则不用。

p.6 結果③観点別の評価点

1:20 累計 6:00

3つ目も新しい実験です。対照学習を使った以前の実験では、信号と学習方法の2つを同時に変えていたため、どちらが効いているのか分かりませんでした。そこで今回は、学習方法は同じ二値分類のまま、信号だけを、6つの観点別の評価点から、総合評価点1つに替えました。

> 第三个也是新实验。之前用对比学习做的实验，同时改变了信号和学习方法两个因素，所以不知道是哪一个起了作用。因此这次学习方法保持同样的二分类，只把信号从 6 个分项评分换成 1 个总评分。

結果は表のとおりです。観点別の評価点では、事前学習なしより1.85ポイント良くなりますが、総合評価点だけにすると、逆に4.44ポイント悪くなりました。観点別と総合の差は、DeBERTaで6.29ポイント、XLM-Rでも3.82ポイントです。

> 结果如表所示。用分项评分时，比无预训练高 1.85 个点；只用总评分时，反而低了 4.44 个点。分项与总评分的差，在 DeBERTa 上是 6.29 个点，在 XLM-R 上也有 3.82 个点。

総合評価点の予測自体はうまく学習できていたので、学習の失敗ではありません。レビュー全体が良いか悪いかだけを学ぶと、観点の区別が失われてしまうのだと考えています。

> 总评分本身的预测学得很好，所以不是训练失败。我认为，只学习整条评论好不好，会让模型丢失对方面的区分。

ただし、総合評価点だけで比べると、対照学習の方が二値分類より良かったので、「二値分類の方が優れている」とは言えません。言えるのは、効いているのは「どの観点が悪かったか」という情報だ、ということです。総合評価点を使ったマルチタスク学習に効果がなかったという先行研究とも整合します。

> 不过，只看总评分时，对比学习比二分类更好，所以不能说「二分类更优」。能说的是：起作用的是「哪个方面不好」这一信息。这也与「用总评分做多任务学习没有效果」的先行研究一致。

新对照实验：只换信号。分项 +1.85，只用总评分反而 −4.44；差 6.29 / 3.82；不是训练失败；总评分下对比学习比二分类好，所以不能说二分类更好；有效的是「哪个方面差」的信息。

p.7 結果④ モデルによる違い

1:10 累計 7:10

4つ目は、モデルを変えた場合です。グラフは、事前学習なしの性能が低い順に、下から並べています。

> 第四个是换模型的情况。图中按无预训练时的性能从低到高，从下往上排列。

XLM-R baseとDeBERTaでは、約1.9ポイントと明確に改善しました。しかし、強いモデルほど改善は小さくなり、BERT largeとModernBERTでは、テストでは有意でしたが、検証データでは逆の方向でした。そして、最も強いLUKEでは効果がありませんでした。同じXLM-Rでも、baseでは1.91ポイント改善したのに対し、largeでは0.58ポイントの低下で、有意な差はありませんでした。

> 在 XLM-R base 和 DeBERTa 上，提高约 1.9 个点，效果明确。但是，越强的模型提高越小：BERT large 和 ModernBERT 在测试集上显著，但在验证数据上方向相反。而在最强的 LUKE 上没有效果。同样是 XLM-R，base 提高了 1.91 个点，而 large 下降了 0.58 个点，没有显著差异。

したがって、「どのモデルでも効く」とは言えません。強いモデルでは効果が小さい、または無いことを、論文では限界として明確に書くつもりです。

> 因此，不能说「对任何模型都有效」。对于强模型上效果小或没有效果这一点，我打算在论文中作为局限明确写出。

换 6 种底座：弱的明确有效，越强越小；XLM-R large 和最强的 LUKE 无效（同为 XLM-R，base +1.91、large −0.58）；作为局限写明。

p.8 他のモデルとの比較

0:50 累計 8:00

他のモデルとも比較しました。同じデータ分割と同じ指標で、エンコーダを7種類、ローカルで動くLLMを4種類評価しています。

> 也和其他模型做了比较。在同样的数据划分和同样的指标下，评估了 7 种编码器和 4 种可以在本地运行的 LLM。

モデルの違いによる差は約9ポイントあり、事前学習による改善よりも大きいです。一方、LLMは学習をせず、指示と20個の例だけを与えた場合、最も良いものでも0.629で、mBERTにも届きませんでした。

> 模型不同带来的差异约为 9 个点，比预训练带来的提高更大。另一方面，LLM 在不训练、只给指令和 20 个例子的情况下，最好的也只有 0.629，连 mBERT 都没有达到。

GPT-4oなどの外部サービスは、データの利用規約により使っていません。これについては、最後にご相談させてください。

> GPT-4o 等外部服务，由于数据使用条款的限制没有使用。这一点想在最后和老师商量。

换底座差约 9 点，大于本手法；本地 LLM 不训练时最好 0.629，低于 mBERT；GPT-4o 因条款未用，最后商量。

p.9 効く条件と、効かなかった試み

1:00 累計 9:00

効く条件と、効かなかった試みをまとめます。事前学習のデータは約200万件で頭打ちになり、新しい年代のデータほど効果がありました。ただし、この2つは各1回の実行なので、参考扱いです。

> 总结一下起作用的条件和没有奏效的尝试。预训练数据在约 200 万条时到顶，越新年代的数据效果越好。不过这两项各只跑了一次，只作参考。

本文に観点の語がある低評価だけを残すノイズ除去は、かえって1.08ポイント悪化しました。食事の評価点を朝食と夕食に分ける試みも、5回の実行で改善はありませんでした。

> 只保留正文中提到该方面词语的低分评论的去噪处理，反而下降了 1.08 个点。把餐食评分拆成早餐和晚餐的尝试，在 5 次运行中也没有提高。

改善が起きた文を分析すると、3つのモデルとも、暗示的なネガティブ全般で改善しており、特定の種類の文に集中しているわけではありませんでした。

> 分析发生提高的句子后发现，三个模型都是在隐式负面上普遍提高，并没有集中在某一类句子上。

约 200 万饱和、近年更好（各 1 次，参考）；过滤噪声有害；餐食拆分无效；增益普遍，不集中于某类句子。

p.10 限界

0:40 累計 9:40

限界は6つです。強いモデルでは効果が小さい、または無いこと。暗示と明示の区別が辞書による自動判定で、人手の検証をしていないこと。データセットが1つであること。サービスと食事が改善しないこと。データ量と年代の実験が各1回であること。そして、LLMとの比較がローカルモデルに限られることです。いずれも論文に明記します。

> 局限有 6 点：在强模型上效果小或没有效果；隐式与显式的区分是用词典自动判定的，没有人工验证；只有一个数据集；服务和餐食没有提高；数据量和年代的实验各只做了一次；以及与 LLM 的比较只限于本地模型。这些都会在论文中写明。

6 条局限，全部写进论文。

p.11 論文にできるか — 構成と計画

0:50 累計 10:30

以上から、論文にできると考えています。主張の3点、つまり、ネガティブ検出の改善、ラベル効率、そして観点別の信号が必要であることは、事前に決めた検定で支持されました。限界も実験で明らかになっており、すべての数字は保存した予測から再計算できます。

> 综上，我认为可以写成论文。三个主张，即负面检测的提高、标注效率、以及需要分项信号，都得到了事先定好的检验的支持。局限也通过实验弄清楚了，所有数字都能从保存的预测结果重新计算。

論文は英語で、右の9章構成を考えています。10月後半に図表と3章から5章を書き、11月末に中間稿、12月末に初稿を目指します。提出日に合わせて調整します。

> 论文用英文写，打算采用右边的 9 章结构。10 月下旬写图表和第 3 到 5 章，11 月底完成中期稿，12 月底完成初稿。会根据提交日期调整。

能写成论文：三个主张有事先定好的检验支持，局限清楚，数字可复算；英文 9 章；日程。

p.12 ご相談したいこと

対話 時間は先生次第

① 1つ目は、実験をここで締めて、執筆に移ってよいかどうかです。追加するとすれば、観点別の評価点と対照学習の組み合わせ、データ量の実験の回数追加、暗示と明示の人手による検証が候補です。私としては、これらは限界として書き、執筆を優先したいと考えています。

> 第一，是否可以在这里结束实验、转入写作。如果要追加，候选有：分项评分与对比学习的组合、增加数据量实验的运行次数、隐式与显式的人工验证。我个人希望把这些作为局限写出，优先写作。

② 2つ目は、強いモデルで効果がないことを、論文でどの程度前面に出すべきかです。私は、結果の章で正面から示し、考察で理由を議論するのがよいと考えています。

> 第二，在论文中应该把「强模型上没有效果」放到多突出的位置。我认为应该在结果一章正面展示，在考察中讨论原因。

③ 3つ目は、GPT-4oなどの外部APIとの比較です。データの利用規約では、楽天が認めた生成AI以外にデータを入力できません。比較があると説得力が増しますが、申請すべきか、ご意見をいただけますか。

> 第三，与 GPT-4o 等外部 API 的比较。数据使用条款规定，不能把数据输入乐天认可之外的生成式 AI。有这个比较会更有说服力，想听听老师的意见：是否应该申请?

④ 4つ目は、データの利用規約についてです。論文や発表の前に楽天への通知が必要なこと、研究の終了時にデータを削除する必要があることを確認させてください。また、開発中に、AIのコーディング支援ツールの出力に、レビューの本文が一部表示されてしまったことがありました。この扱いについてもご相談させてください。

> 第四，关于数据使用条款。想确认：在论文和发表之前需要通知乐天；研究结束时需要删除数据。另外，开发过程中，AI 编程辅助工具的输出里曾显示过一部分评论原文，这件事的处理也想和老师商量。

⑤ 最後に、題目、提出日、発表の時間を教えていただければ、計画を確定させます。

> 最后，如果老师能告诉我题目、提交日期和发表时间，我就把计划定下来。

一条一条问，等老师回答：①停实验转写作？②强底座无效怎么写？③GPT-4o 是否申请？④数据条款（通知、删除、AI 工具输出露出原文）⑤题目/截止日/发表时长。

そうていもんどう
想定問答

先生に聞かれそうな質問と回答例です。「可能性 高」から練 習してください。「回答を隠す」を押すと回答がぼやけ、タップすると表示されます。

Q1 可能性 高 結果·統計

1～2ポイントの改善に、意味はありますか。

提高 1–2 个点有意义吗?

回答例

数値は大きくありませんが、3つの理由で意味があると考えています。

> 数值并不大，但我认为有三点理由说明它有意义。

1つ目は安定していることです。信頼区間はゼロを含まず、9回の実行すべてが基線の最高値を上回っています。2つ目は、追加の人手ラベルが要らないことです。3つ目は、ラベル量の実験から、人手ラベルを約半分に減らしても同じ水 準を保てると分かったことです。

> 第一，它是稳定的：置信区间不含 0，9 次运行全部高于基线的最高值。第二，不需要额外的人工标注。第三，从标注量的实验可知，即使把人工标注减少到大约一半，也能保持同样的水平。

稳定（CI 不含 0、9 次全高于基线最高值）、零标注成本、相当于省一半标注。

Q2 可能性 中 結果・統計

同じ設定で実行しても、結果が変わるのですか。

同一设定重跑结果会变吗?

回答例

はい。GPUの計算の非決定性により、同じ設定、同じseedでも、最大0.7ポイントほど揺れます。

> 是的。由于 GPU 计算的非确定性，即使设定和 seed 都相同，结果也会有最多约 0.7 个点的波动。

そのため、1回の結果ではなく複数回の分布で比べ、paired bootstrapで信頼区間を求めています。

> 所以我们不比较单次的结果，而是比较多次运行的分布，并用 paired bootstrap 求出置信区间。

会，最多约 0.7 点（GPU 非确定性），所以比较多次运行的分布。

Q3 可能性 中 結果・統計

paired bootstrapとは何ですか。

paired bootstrap 是什么?

回答例

テスト文を、重複を許して抽出し直し、2つのモデルの差を計算することを2,000回繰り返して、差の分布から信頼区間を求める方法です。

> 这是一种方法：对测试句子进行允许重复的重新抽样，计算两个模型的差，重复 2,000 次，再从差的分布求出置信区间。

同じ文で比べるので、文の難しさによるばらつきが打ち消されます。複数回の実行は、平均してから差をとっています。

> 因为是在同一批句子上比较，句子难易带来的波动会相互抵消。多次运行的结果先取平均，再求差。

对测试句有放回重抽样 2000 次，算两模型之差的分布；同一批句子比较，抵消句子难度；多次运行先平均。

Q4 可能性 高 新しい実験

Goldが半分で同程度というのは、本当に同じと言えるのですか。

一半 Gold 就「相当」，真的能说一样吗?

回答例

厳密には「有意な差がない」ということで、同じであることを証明したわけではありません。

> 严格来说，这是「没有显著差异」，并没有证明两者相同。

50パーセントのときの差はプラス0.47で、信頼区間はマイナス0.42からプラス1.33です。論文では「有意差なし」と書き、37パーセントという値は参考値として示します。

> 50% 时的差是 +0.47，置信区间是 −0.42 到 +1.33。论文中会写「无显著差异」，37% 这个值只作为参考值给出。

严格说是「无显著差」，不是证明等价；50% 时 +0.47 [−0.42, +1.33]；37% 只作参考值。

Q5 可能性 中 新しい実験

なぜ学習回数を変えたのですか。都合の良い設定を選んだのではありませんか。

为什么改训练轮数？是不是挑了对自己有利的设定?

回答例

データが少ないと更新回数が減り、事前学習なしのモデルが学習不足になるためです。

> 因为数据少时更新次数会减少，无预训练的模型会训练不足。

どちらの設定を使うかは、実験の前に、事前学習なしのモデルの検証データの値で決めるというルールを決めておきました。基線に有利な方を選ぶルールです。固定回数の方が差は大きく出ますが、採用していません。両方の結果を報告します。

> 用哪种设定，是在实验之前就定好的规则：按无预训练模型在验证数据上的结果来决定，也就是选对基线有利的那一种。固定轮数时差会显得更大，但我们没有采用。两种结果都会报告。

数据少则更新步数少、基线训练不足；用哪种是事先定的：按基线的验证集选对基线有利的那种；固定轮数差更大但没采用；两者都报告。

Q6 可能性 高 新しい実験

総合評価点だと悪くなるのはなぜですか。

为什么只用总评分反而变差?

回答例

総合評価点の予測自体は、観点別のどの出力よりも高い精度で学習できていたので、学習の失敗ではありません。

> 总评分本身的预测，学得比任何一个分项输出的精度都高，所以不是训练失败。

レビュー全体が良いか悪いかだけを学ぶと、エンコーダが全体の印象に引っ張られ、下流で必要な観点の区別が失われるのだと考えています。ただし、この解釈は検証していないので、論文では仮説として書きます。

> 我认为，只学习整条评论好不好，编码器会被整体印象牵着走，下游需要的方面区分就丢失了。不过这个解释没有经过验证，论文中会作为假说来写。

不是训练失败（总评分预测学得比任何分项都好）；推测：只学整体好坏，会抹掉方面区分；作为假说写。

Q7 可能性 中 新しい実験

対照学習と二値分類は、どちらが良いのですか。

对比学习和二分类哪个好?

回答例

総合評価点を使う場合は対照学習の方が良く、観点別の評価点では二値分類しか試していません。そのため、どちらが良いかは一般には言えません。

> 使用总评分时，对比学习更好；而分项评分只试了二分类。所以一般地说不出哪个更好。

言えるのは、どちらの方法でも、総合評価点だけでは全体のネガティブ検出は改善しない、ということです。観点別と対照学習の組み合わせは、残っている候補の1つです。

> 能说的是：无论哪种方法，只用总评分都不能提高整体的负面检测。分项评分与对比学习的组合，是剩下的候选之一。

总评分下对比学习更好；分项只试了二分类，不能一般地说哪个好；能说的是只用总评分两种方法都不提升整体负面。

Q8 可能性 高 比較·限界

強いモデルで効果がないなら、この手法は役に立たないのではありませんか。

强模型上无效，这个方法是不是没用?

回答例

強いモデルでの効果が小さいことは、正直に認めるべき結果だと考えています。

> 强模型上效果小，我认为这是应该坦率承认的结果。

ただ、比較的小さいモデルでは明確な改善があり、ラベルを約半分に減らせることも示しました。計算資源やモデルの選択に制約がある場面では意味があると考えています。論文では、効果がある範囲とない範囲の両方を示します。

> 不过，在相对较小的模型上有明确的提高，而且也表明了可以把标注减少到大约一半。在计算资源或模型选择受限的场景下，我认为是有意义的。论文中会同时写出有效和无效的范围。

坦率承认；但在较小的模型上明确有效，且能省一半标注；在资源受限场景有意义；论文写清有效和无效的范围。

Q9 可能性 中 比較·限界

なぜ強いモデルでは効かないのですか。

为什么强模型上无效?

回答例

まだ検証していませんが、強いモデルは、評価点から学べるような知識をすでに持っているため、上乗せの余地が小さいのだと考えています。

> 还没有验证，但我认为，强模型已经具备了能从评分中学到的那类知识，所以再往上加的空间小。

論文では仮説として書きます。

> 论文中会作为假说来写。

未验证；推测强模型已有类似知识，提升空间小；作为假说写。

Q10 可能性 中 比較・限界

LLMを微調整すれば、もっと良くなるのではありませんか。

LLM 微调后会不会更好?

回答例

その可能性はあります。今回は、ローカルのLLMを学習なしで、指示と20個の例だけで評価しました。

> 有这种可能。这次只评估了不训练、只给指令和 20 个例子的本地 LLM。

LLMの微調整は計算コストが大きいので行っていません。論文では、学習なしのLLMとの比較に限られることを、限界として書きます。

> LLM 的微调计算成本大，所以没有做。论文中会把「只与不训练的 LLM 比较」作为局限写出。

有可能；这次只评估了不训练的本地 LLM；微调成本高没做；写成局限。

Q11 可能性 中 比較・限界

暗示的と明示的の区別はどうしているのですか。信頼できますか。

隐式/显式怎么区分？可靠吗?

回答例

日本語の感情極性辞書を使い、文の中に否定的な語が1つでもあれば明示的、なければ暗示的としています。

> 使用日语情感极性词典：句子中只要有一个负面词就算显式，没有就算隐式。

自動判定で、人手による検証はしていないので、限界として書きます。人手検証用のサンプルは準備してあるので、必要であれば実施できます。

> 这是自动判定，没有经过人工验证，所以会作为局限写出。人工验证用的样本已经准备好了，如果需要可以实施。

用日语情感极性词典：句中有负面词=显式，否则隐式；自动判定未人工核验，写成局限；样本已备好，需要可以做。

Q12 可能性 低 比較・限界

先行研究と比べて、性能はどの程度ですか。

和先行研究比性能如何?

回答例

研究ごとにデータの分割や指標が違うので、直接は比べられません。

> 各研究的数据划分和指标不同，不能直接比较。

参考までに、このデータの元論文のBERTは、14ラベルの平均で0.711です。本研究では同じ分割で、エンコーダを7種類、LLMを4種類比較しています。

> 作为参考，这份数据的原论文中 BERT 的 14 个标签平均是 0.711。本研究在同一划分下比较了 7 种编码器和 4 种 LLM。

划分和指标不同，不能直接比；参考：原论文 BERT 14 标签平均 0.711；本研究在同一划分下比较了 7 个编码器和 4 个 LLM。

Q13 可能性 中 論文・今後

スケジュールは間に合いますか。

进度来得及吗?

回答例

実験は終わっているので、残りは執筆と図表です。11月末に中間稿、12月末に初稿を目指しています。

> 实验已经结束，剩下的是写作和图表。目标是 11 月底完成中期稿，12 月底完成初稿。

提出日が分かれば逆算して確定させ、遅れそうな場合は早めにご相談します。

> 知道提交日期后会倒推确定日程，如果可能延误会尽早和老师商量。

实验已完，剩写作和图表；11 月底中间稿、12 月底初稿；知道截止日后倒推确定。

Q14 可能性 低 論文・今後

再現性はどう確保していますか。

怎么保证可复现?

回答例

実験の計画と判定の基準を実験の前に文書に書き、すべての実行の設定と予測結果を保存しています。

> 实验的计划和判定标准在实验之前就写成了文档，所有运行的设定和预测结果都保存了下来。

論文のすべての数字は、保存した予測から再計算でき、確認用のスクリプトも用意しています。

> 论文中所有的数字都能从保存的预测重新计算，也准备了检查用的脚本。

事先写计划和判定标准；保存所有运行的设定和预测；所有数字可复算，有自检脚本。

Q15 可能性 低 論文・今後

データやコードは公開できますか。

数据和代码能公开吗?

回答例

コードは公開できますが、楽天のデータとGoldデータは、利用規約上、再配布できません。

> 代码可以公开，但乐天的数据和 Gold 数据按使用条款不能再分发。

公開する場合は、データを含まない形で準備します。

> 如果公开，会准备不含数据的版本。

代码可以；乐天数据和 Gold 按条款不能再分发；公开时不含数据。

困ったときの一言

答えに詰まったときは、無理に答えず、この言い方で時間を取ってください。

質問が聞き取れなかったとき

すみません、もう一度おっしゃっていただけますか。

没听清时

質問の意図を確認したいとき

ご質問は、〇〇ということでよろしいでしょうか。

确认问题意图

すぐに答えられないとき

今すぐ正確にはお答えできないので、確認して後日ご報告します。

答不上来时（不要现场编数字）

指摘を受け入れるとき

ご指摘ありがとうございます。その点は論文の限界として書きます。

接受批评

反対の意見を伝えたいとき

おっしゃることはよく分かります。ただ、〇〇という理由で、私は〇〇がよいと考えています。

礼貌地表达不同意见

先生が決めてくださったとき

承知しました。では、〇〇の方向で進めます。

老师拍板后确认

考える時間がほしいとき

少し考えさせてください。

需要思考时间

会の終わり

本日決めていただいた内容は、整理して後ほどメールでお送りします。ありがとうございました。

结束时